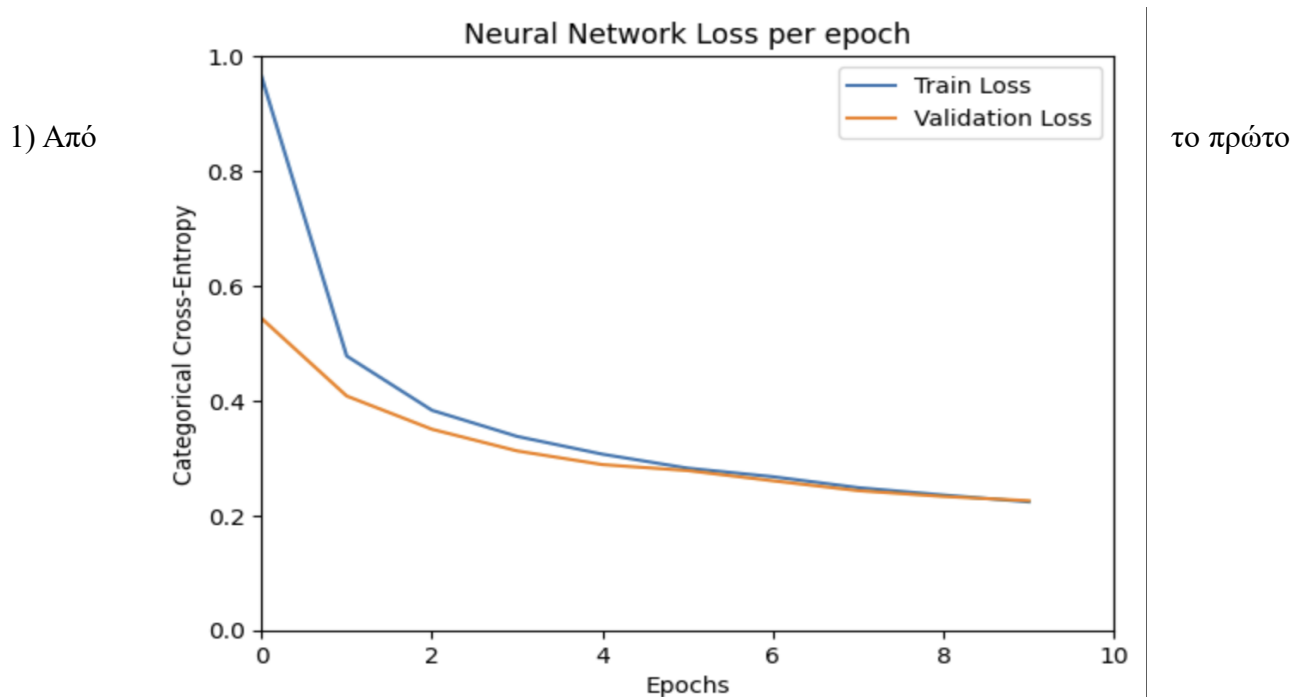


Εργασία Τεχνητής Νοημοσύνης Νο.3


Ανάλυση του υπάρχοντος μοντέλου

Εκ πρώτης όψεως, το μαθησιακό μοντέλο παρουσιάζει ακρίβεια 93% η οποία υποδηλώνει πως βρισκόμαστε σε ένα αρκετά καλό στάδιο. Παρ'όλα αυτά, εάν αναλύσουμε τα γραφήματα που μας δίνονται καταλήγουμε στα εξής συμπεράσματα:



διάγραμμα, παρατηρούμε πως οι δύο καμπύλες συμπίπτουν σε ένα σχετικά υψηλό σημείο, το οποίο σημαίνει πως το μοντέλο αξιολογεί με την ίδια επιτυχία εικόνες που χρησιμοποίησε για να εκπαιδευτεί καθώς και εικόνες που συναντούσε πρώτη φορά. Ιδανικά θα περιμέναμε η καμπύλη του “Train Loss” να βρίσκεται σε χαμηλότερη θέση, το οποίο θα σήμαινε πως το μαθησιακό μοντέλο θα είχε εκπαιδευτεί καλύτερα στις εικόνες που χρησιμοποίησε για την διαδικασία της μάθησης. Υπό διαφορετικές συνθήκες, θα έπρεπε και η καμπύλη του “Validation Loss” να βρίσκεται και αυτή προς το 0, όμως για λόγους που θα αναλυθούν παρακάτω αυτό στη συγκεκριμένη περίπτωση δεν θα επιτευχθεί.

Παρατήρηση: Οι καμπύλες διαμορφώνονται αρκετά ομαλά, το οποίο δικαιολογείται από τον χαμηλό ρυθμό μάθησης που χρησιμοποιήθηκε (Learning rate = 0.001)



2) Από το δεύτερο διάγραμμα, παρατηρούμε πως υπάρχει περιθώριο βελτίωσης του μαθησιακού μοντέλου γιατί, αν και στο υψηλό επίπεδο του 93%, το μοντέλο φαίνεται πως αξιολογεί με την ίδια ακρίβεια εικόνες που έχει χρησιμοποιήσει για να εκπαιδευτεί, καθώς και εικόνες που χρησιμοποίησε για έλεγχο. Είναι πρακτικά αδύνατο να φτάσουν οι δύο καμπύλες στο 1.0, θα ήταν λογικό ωστόσο να βλέπαμε την καμπύλη του “Train Accuracy” υψηλότερα από την καμπύλη του “Validation Accuracy”. Εξυπακούεται εξάλλου πως ένα οποιοδήποτε αποδοτικό μαθησιακό μοντέλο έχει μεγαλύτερη επιτυχία σε εικόνες που βλέπει ξανά και ξανά (ανάλογα τον αριθμό των epochs) παρά σε εικόνες που αξιολογεί για πρώτη φορά. Έτσι λοιπόν καταλαβαίνουμε πως πρέπει να βελτιώσουμε το μοντέλο στη διαδικασία της εκπαίδευσης.


Βελτιώσεις και επιπρόσθετες παρατηρήσεις

Πρώτο βήμα, ήταν η βελτίωση της ακρίβειας από 93% σε 99% μέσω της αντικατάστασης της συνάρτησης ‘tanh’ από την συνάρτηση ‘relu’. Αναλυτικά, η ακρίβεια σε σχέση με τον αριθμό επαναλήψεων (epochs) έχει ως εξής:


	tanh	Relu
1	0.72	0.88
2	0.87	0.94
3	0.89	0.96
4	0.90	0.97
5	0.91	0.97
6	0.91	0.98
7	0.92	0.99

8	0.92	0.99
9	0.93	0.99
10	0.93	0.99

Με δεδομένη την υψηλή ακρίβεια του 99% θα έλεγε κανείς πως έχουμε στα χέρια μας ένα αρκετά ικανό μαθησιακό μοντέλο το οποίο είναι ικανό να λάβει σωστές αποφάσεις. Παρ'όλα αυτά, εάν εξετάσουμε εκ νέου τα διαγράμματα που προκύπτουν από την αλλαγή στην ακρίβεια παρατηρούμε το εξής:




Θα εξετάσουμε πρώτα το 2ο διάγραμμα, αυτό της ακρίβειας το οποίο δείχνει την αύξηση που παρατηρήσαμε προηγουμένως στα ποσοστά. Οι προβληματισμοί θα προκύψουν από το 1ο διάγραμμα.



Εδώ βλέπουμε πως ενώ η καμπύλη του “Train Loss” έχει χαμηλώσει αρκετά, η καμπύλη του “Validation Loss” παραμένει σε σχετικά ίδια θέση. Από αυτό συμπεραίνουμε ότι ενώ το μαθησιακό μοντέλο μαντεύει πλέον σωστά τους αριθμούς τους οποίους έχει ξανά δει (που έχουν χρησιμοποιηθεί δηλαδή στη διαδικασία της εκπαίδευσης και στη προσαρμογή των βαρών μέσω της διαδικασίας back propagation) παρουσιάζει αδυναμία στην λήψη σωστής απόφασης σε εικόνες που δεν έχουν χρησιμοποιηθεί στη διαδικασία της μάθησης. Αυτό κατά πάσα πιθανότητα οφείλεται στα δεδομένα που χρησιμοποιήθηκαν.

Σχολιασμός πάνω στα δεδομένα

Από μία γρήγορη ματιά πάνω στα δεδομένα που χρησιμοποιήθηκαν και που μπόρεσα να αναλύσω διαπιστώνονται οι εξής ενδεικτικές ασάφειες:



- 1) Ασαφής σχεδιασμός του αριθμού ‘1’ σε αρκετές εικόνες στις οποίες μοιάζει περισσότερο στο ‘/’
- 2) Χρήση διαφορετικού “paint brush” για τον σχεδιασμό των αριθμών, οδηγώντας έτσι σε επιβαρυντική ποικιλία του πάχους των αριθμών
- 3) Έλλειψη ποικιλίας στην απεικόνιση των αριθμών που μπορούν να γραφθούν με διαφορετικούς τρόπους (πχ ‘1’, ‘4’, ‘7’)

Σε γενικότερο πλαίσιο, οι λόγοι που μπορούν να οδηγήσουν στην απόσταση μεταξύ των δύο αυτών καμπυλών είναι οι εξής:

- 1) Ασαφής δεδομένα (αναλύθηκε παραπάνω)
- 2) Λάθος διαχωρισμός δεδομένων (εδώ το 85% των εικόνων χρησιμοποιήθηκε για εκπαίδευση ενώ το 15% για έλεγχο, ιδανικά θα θέλαμε διαμέριση 80/20)
- 3) Λίγα δεδομένα / ανεπαρκής αριθμός για την μάθηση του συστήματος

Επομένως, σε δεύτερο στάδιο, για να πετύχουμε μεγαλύτερη ακρίβεια σε εικόνες που δεν έχει χρησιμοποιήσει το μαθησιακό μοντέλο για να εκπαιδευτεί, θα δουλεύαμε πάνω στα δεδομένα.

Απαντήσεις στις ερωτήσεις κατανόησης

α) Θεωρείτε πως τα δεδομένα της MNIST είναι καλά για την εκπαίδευση ενός μοντέλου? Αιτιολογείστε.

Τα δεδομένα της MNIST έχουν το πλεονέκτημα ότι, έπειτα από επεξεργασία (πχ κεντράρισμα των χαρακτήρων), αποτελούν ένα αρκετά απλό dataset στο οποίο είναι εύκολο να επιτευχθεί υψηλή ακρίβεια. Για αυτό τον λόγο λοιπόν, για να γίνει σωστή αξιολόγηση σε άλλα μαθησιακά μοντέλα προχωρημένου επιπέδου θα ήταν καλύτερη η χρήση άλλων dataset όπως CIFAR-10 ή ImageNet.

β) Θεωρείτε πως όλα τα pixel είναι σημαντικά για την πρόβλεψη της κλάσης ενός ψηφίου?

Τα pixel που χρησιμοποιούνται για τον σχεδιασμό των αριθμών είναι σημαντικότερα στη λήψη αποφάσεων από τα υπόλοιπα. Έτσι λοιπόν, τα pixel που έχουν τιμή κοντά στο 0.0 (τα μαύρα) συμβάλουν λιγότερο από ο,τι αυτά που είναι άσπρα.

γ) Σε ποιες περιπτώσεις είναι καλή ιδέα να χρησιμοποιηθούν Βαθιά Νευρωνικά Δίκτυα?

Ένα νευρωνικό δίκτυο θεωρείται βαθύ όταν αποτελείται από τουλάχιστον 2 “Hidden Layers”. Παρατηρείται συχνά η χρήση τους όταν τα προβλήματα που έχουμε να αντιμετωπίσουμε είναι περίπλοκα η/και όταν τα δεδομένα δεν έχουν οργανωθεί. Για παράδειγμα, ένα απλό νευρωνικό δίκτυο όπως αυτό που αναλύθηκε παραπάνω για την πρόβλεψη αριθμών δεν θα μπορούσε να χρησιμοποιηθεί σε ένα πιο περίπλοκο πρόβλημα όπως η πρόβλεψη τύπων καρκίνου του δέρματος, το οποίο θα απαιτούσε τη χρήση ενός Deep Neural Network.

δ) Η Βαθιά Μάθηση μπορεί να χρησιμοποιηθεί και στους 3 κλάδους της Μηχανικής Μάθησης? (Supervised Learning, Unsupervised Learning και Reinforcement Learning)

Εν συντομία, ναι. Υπάρχουν διάφορες κατηγορίες προβλημάτων στις οποίες χρησιμοποιούνται αυτές οι τεχνικές μάθησης, η κάθε μία με τα πλεονεκτήματά της αναλόγως με τη φύση του προβλήματος. Παραδείγματος χάρη, σε παρόμοια ζητήματα πρόβλεψης με είσοδο εικόνων, είναι καλύτερη η χρήση του Supervised Learning, αντιθέτως, σε προβλήματα άλλης φύσεως όπως η εκπαίδευση ενός μαθησιακού μοντέλου να παίζει τάβλι, είναι απαραίτητη η χρήση του Reinforcement Learning.